

Gustavo Sanches Lucas Treuke

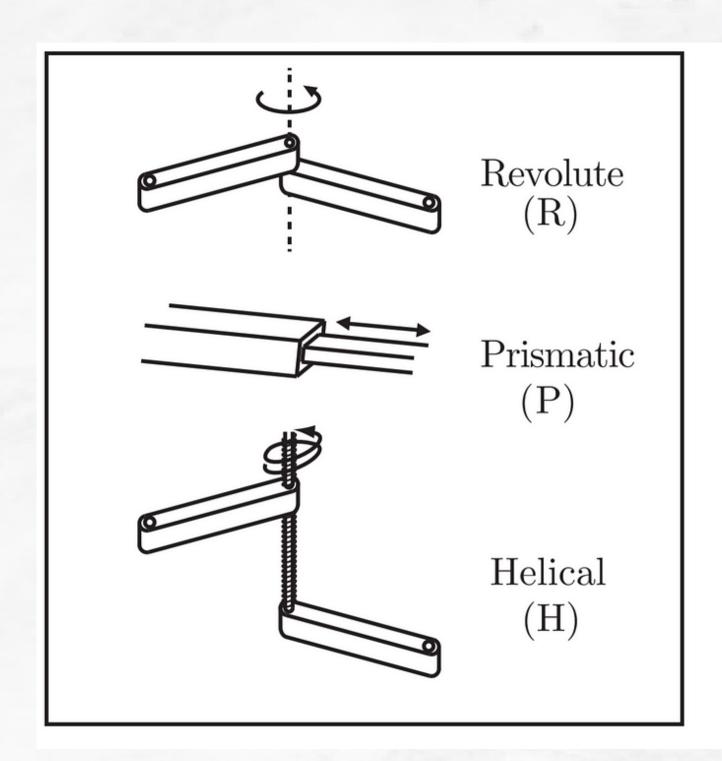


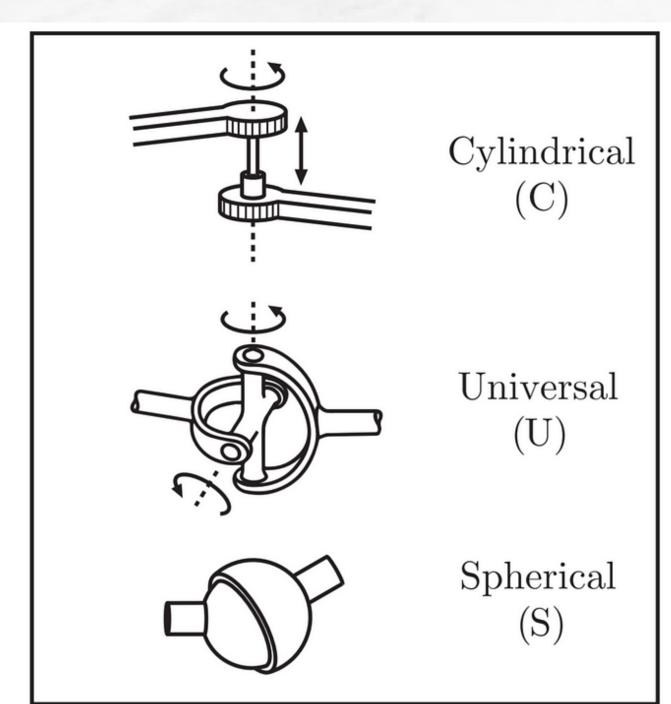




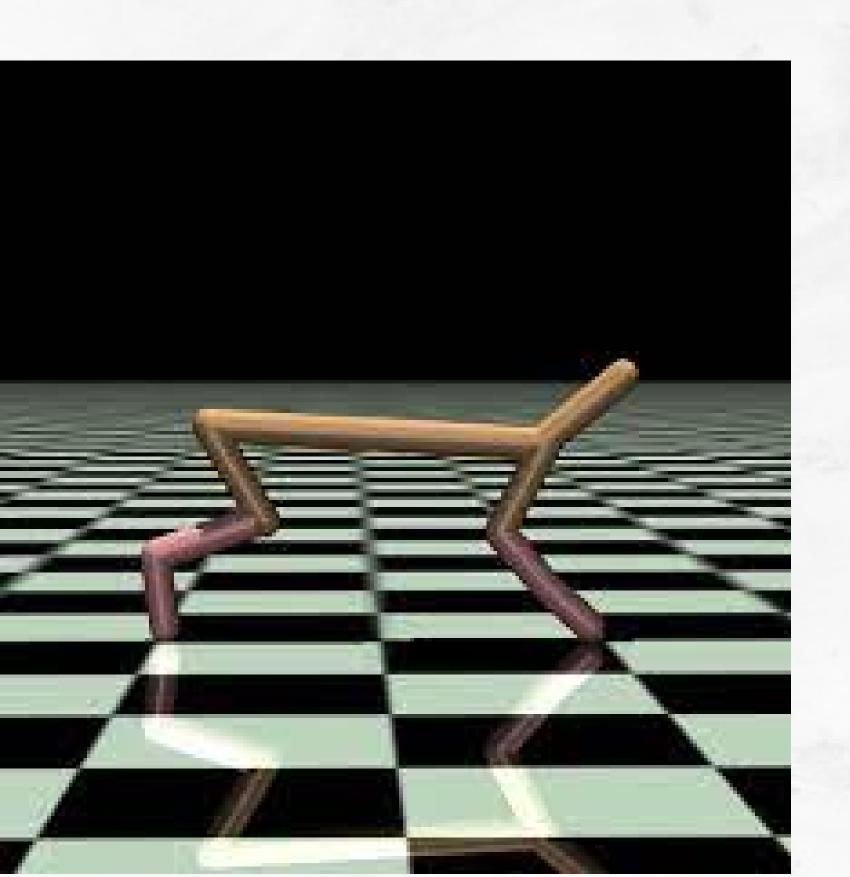


TIPOS DE JUNTAS









HALF CHEETAH

SOBRE

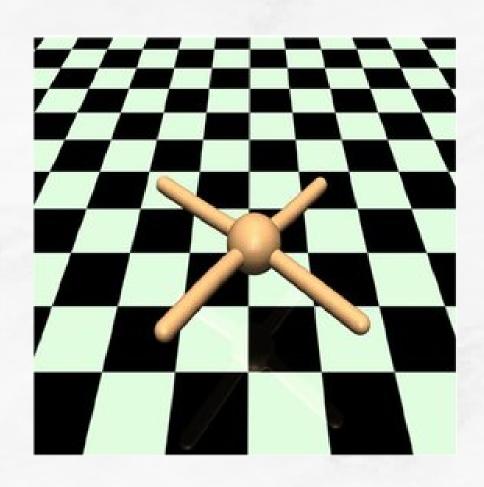
Action Space: (6,1) com valores de -1 a 1

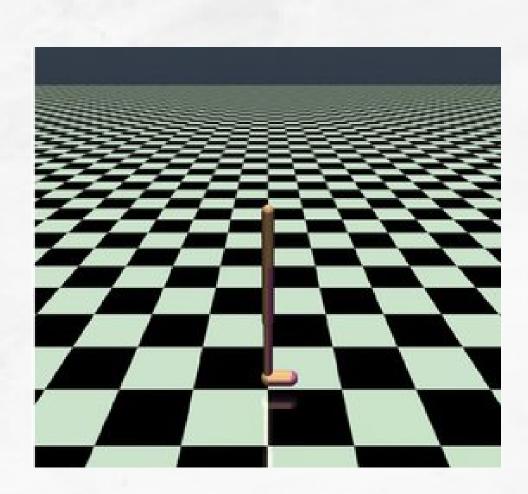
State space: (17,1) com valores de -inf a inf

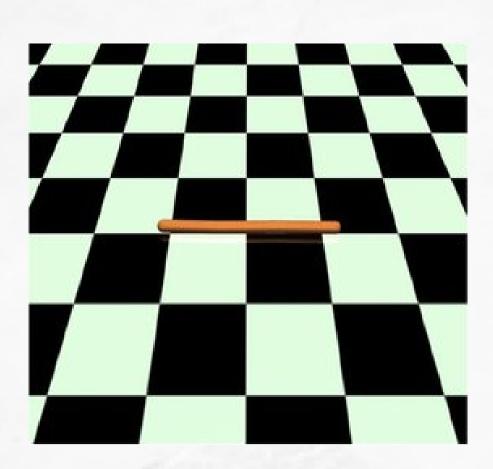
Reward: Distância em x percorrida - tamanho das ações

OUTROS MODELOS









Ant Hopper Swimmer

ALGORITMO



DQL X Actor-critic



DQL resolve o problema de uma alta dimensão no espaço de observação

07

ALTA DIMENSÃO ESPAÇO DE AÇÃO

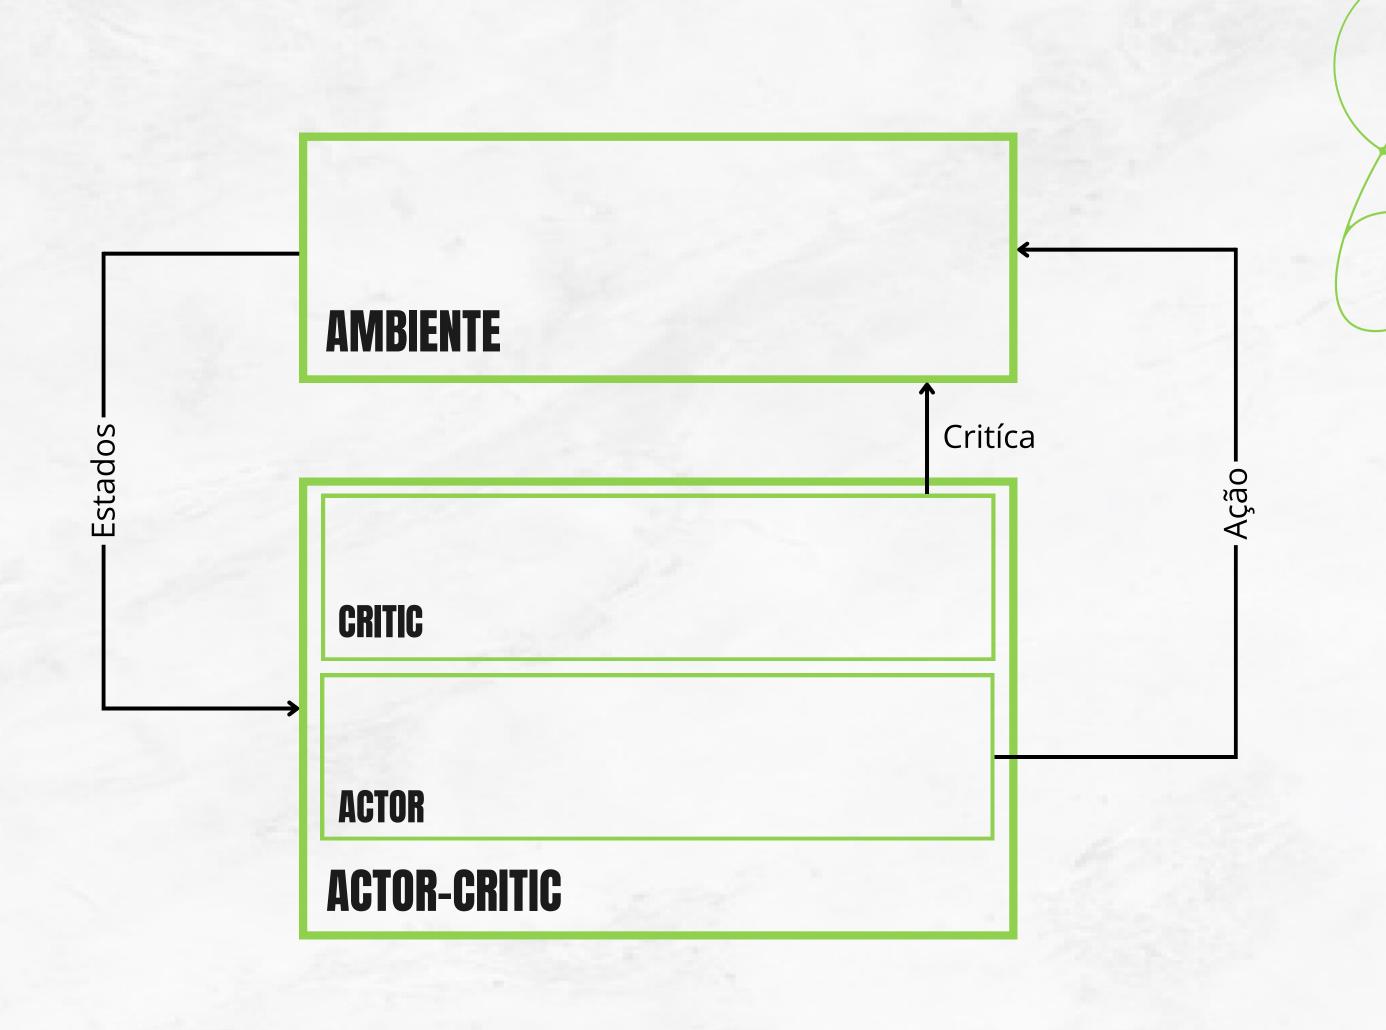
DQL possui dificuldade de lidar com espaços de ação com alta dimensionalidade

POSSIBILIDADE DE DISCRETIZAÇÃO DO ESPAÇO

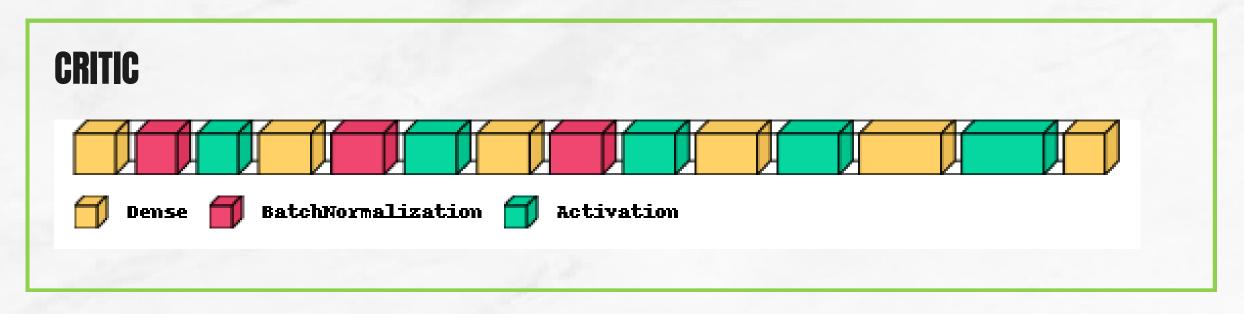
É possível discretizar o espaço de ação para se manter utilizando o DQL

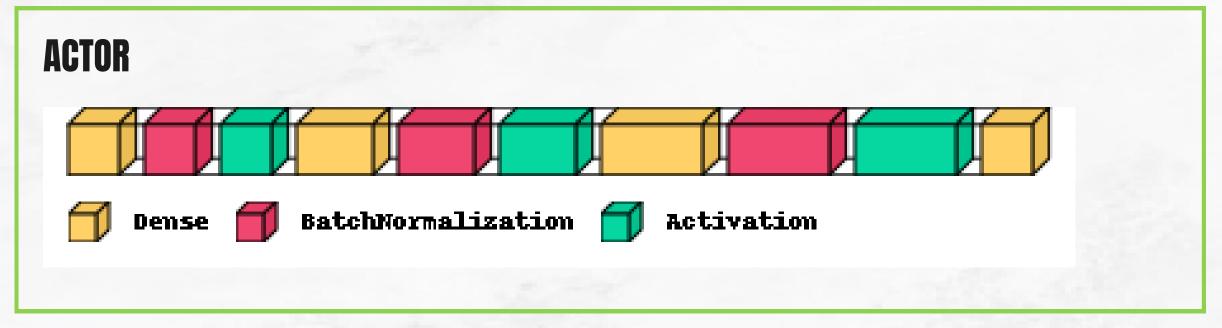
TEMPO DE TREINAMENTO

DQL passa a possuir u tempo de treinamento alto com a discretização do espaço



Redes





OUTRAS CONSIDERAÇÕES

- ADIÇÃO DE RUIDO NA EXPLORAÇÃO estratégias de exploração como epsilon greedy não são utilizadas.
- TREINAMENTO MAIS RÁPIDO

 Tem a tendência de ser mais rápido que os algoritmos de policy gradient comuns.
- DEPENDENTE DO PONTO INICIAL

 A seed influencia fortemente o resultado.

Algorithm 1 DDPG algorithm

Randomly initialize critic network $Q(s, a|\theta^Q)$ and actor $\mu(s|\theta^\mu)$ with weights θ^Q and θ^μ .

Initialize target network Q' and μ' with weights $\theta^{Q'} \leftarrow \theta^Q$, $\theta^{\mu'} \leftarrow \theta^{\mu}$

Initialize replay buffer R

for episode = 1, M do

Initialize a random process N for action exploration

Receive initial observation state s_1

for t = 1, T do

Select action $a_t = \mu(s_t|\theta^{\mu}) + \mathcal{N}_t$ according to the current policy and exploration noise

Execute action a_t and observe reward r_t and observe new state s_{t+1}

Store transition (s_t, a_t, r_t, s_{t+1}) in R

Sample a random minibatch of N transitions (s_i, a_i, r_i, s_{i+1}) from R

Set $y_i = r_i + \gamma Q'(s_{i+1}, \mu'(s_{i+1}|\theta^{\mu'})|\theta^{Q'})$

Update critic by minimizing the loss: $L = \frac{1}{N} \sum_{i} (y_i - Q(s_i, a_i | \theta^Q))^2$

Update the actor policy using the sampled policy gradient:

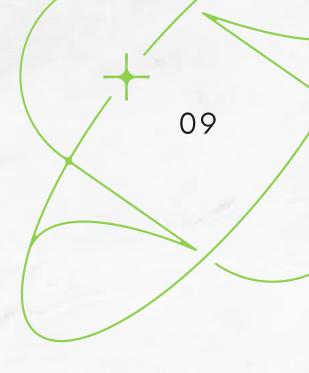
$$\nabla_{\theta^{\mu}} J \approx \frac{1}{N} \sum_{i} \nabla_{a} Q(s, a | \theta^{Q})|_{s=s_{i}, a=\mu(s_{i})} \nabla_{\theta^{\mu}} \mu(s | \theta^{\mu})|_{s_{i}}$$

Update the target networks:

$$\theta^{Q'} \leftarrow \tau \theta^Q + (1 - \tau)\theta^{Q'}$$

$$\theta^{\mu'} \leftarrow \tau \theta^{\mu} + (1 - \tau) \theta^{\mu'}$$

end for end for



RESULTADOS

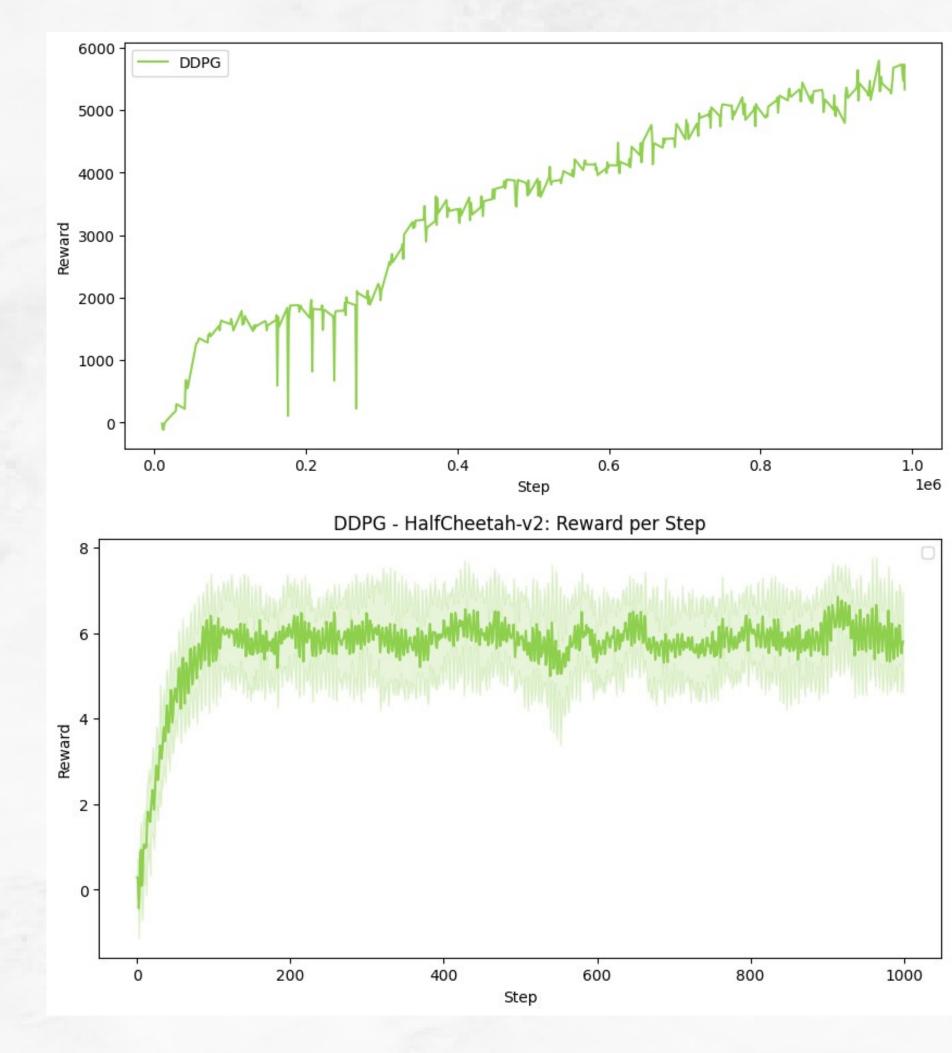


RECOMPENSAS

A recompensa média após 1000 steps é de aproximadamente uma distância de 5000 unidades.

Modelo ganha velocidade e depois estabiliza.

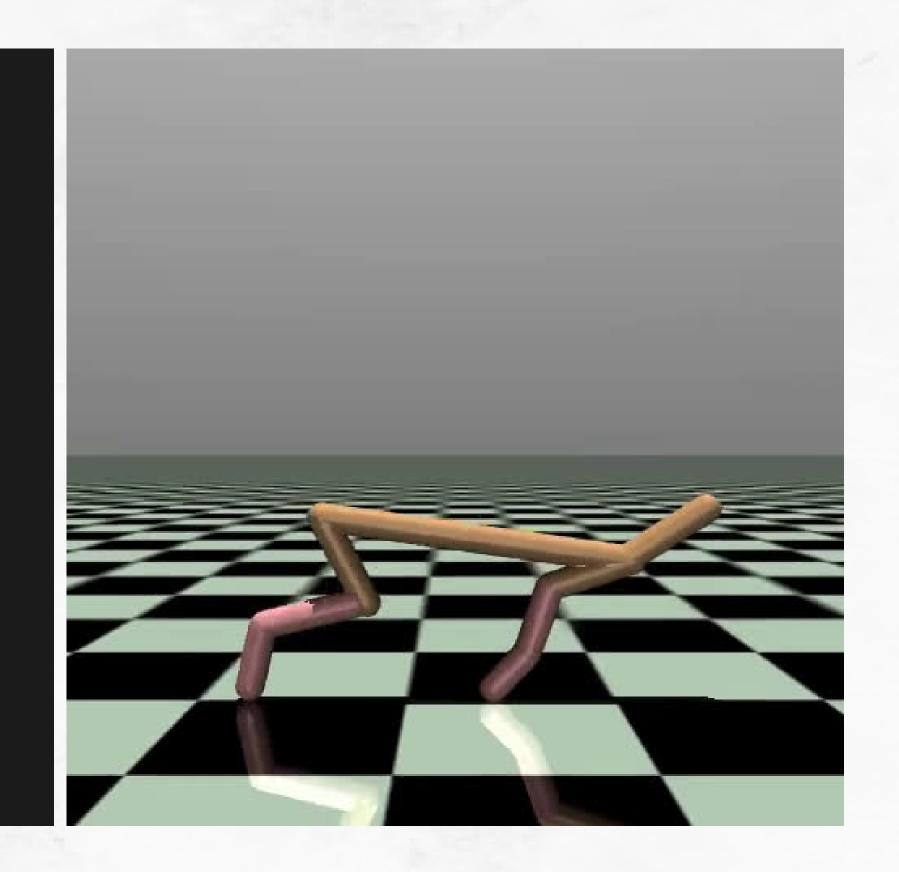
Treinamento durou cerca de 5 horas.



PIOR MODELO

O primeiro teste após uma noite inteira de treinamento e um computador quase queimado resultou nisso....

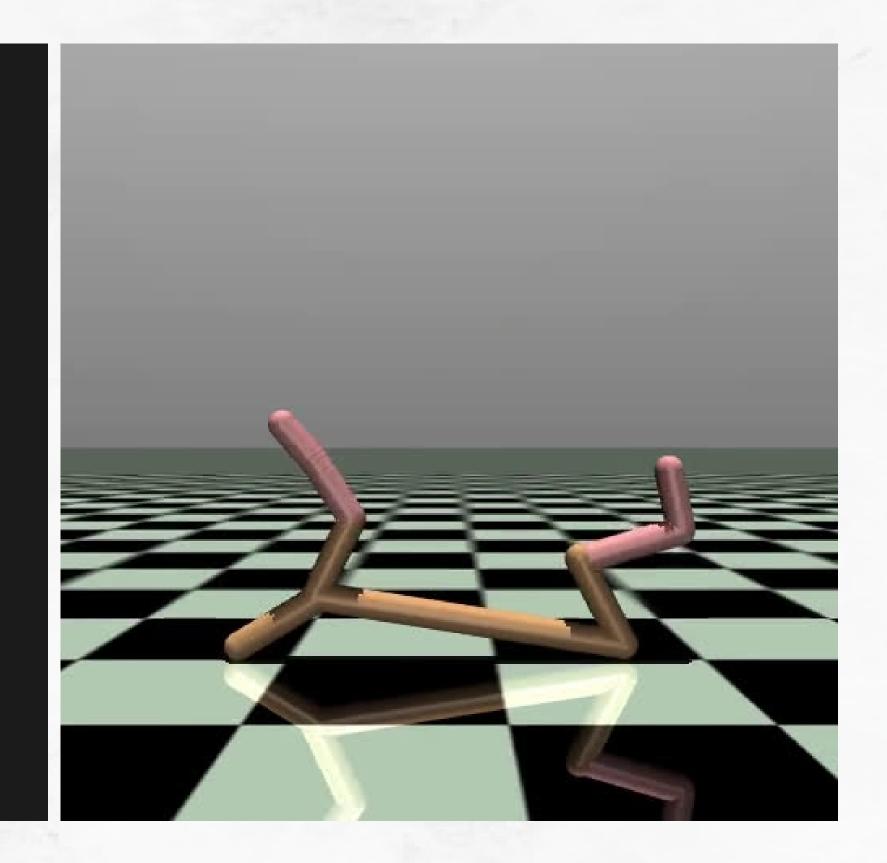
2000 steps por episódio, 200 episódios, código mal otimizado.

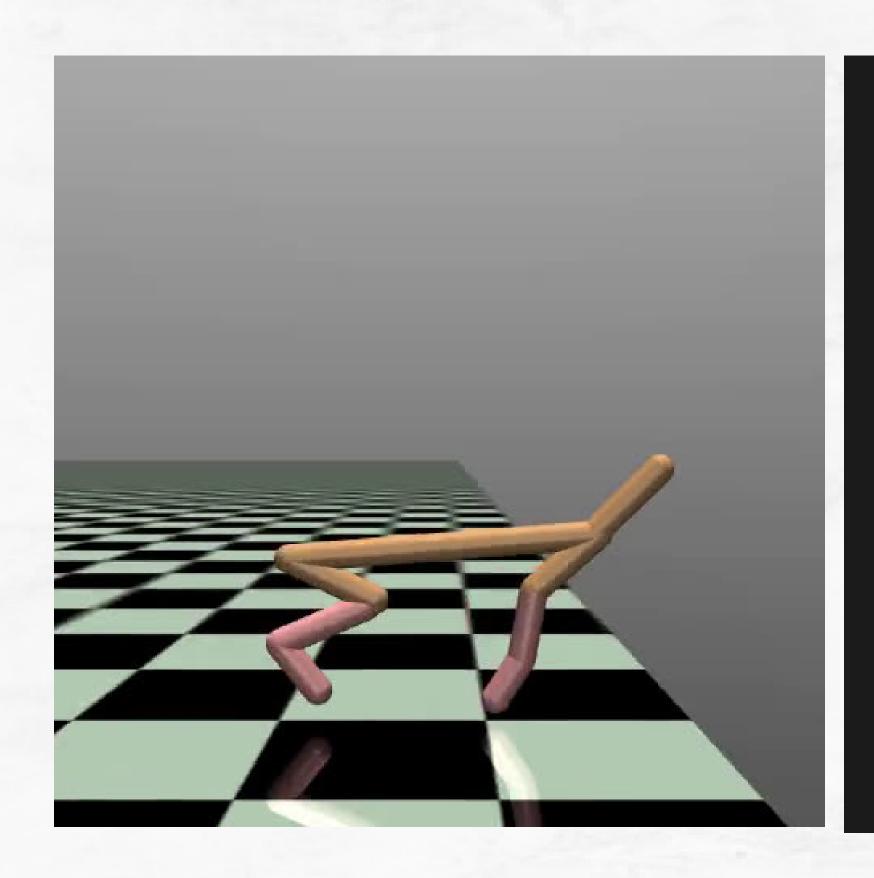


MODELO MEDIO?

Difícil classificar se bom ou ruim, mas durante as tentativas de treinamento ele também aprendeu a andar assim...

200 steps por episódio, 20 episódios





MELHOR MODELO

Após pouco mais de cinco horas de treinamento e muitas tentativas falhas, alcançamos uma marca de 5662 de rcompensa

1000 steps por episódio, 200 episódios

OBRIGADO PELA ATENÇÃO



Gustavo Sanches Lucas Treuke



07

Scott Fujimoto, Herke van Hoof, and David Meger. **Addressing function approximation error in actor-critic methods**, 2018

Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver, and Daan Wierstra. **Continuous control with deep reinforcement learning**, 2019.

Liang, James. Training a Cheetah to run with Deep Reinforcement Learning. Avaiable at https://towardsdatascience.com/training-a-cheetah-to-run-with-deep-reinforcement-learning-6dca2975443a.

Silver, David, et al. "**Deterministic policy gradient algorithms**." International conference on machine learning. Pmlr, 2014.

Bibliografia